

**Una introducción explicando el problema a ser resuelto y una descripción del método de regresión lineal usado.**

A partir de un conjunto de datos con distintas características relacionadas con el valor medio de varias casas, se busca crear un modelo capaz de predecir esto último mediante un entrenamiento con los datos. Además, debemos encontrar el mejor resultado de predicción promedio, por lo que se realizarán numerosas pruebas de regresión estocásticas con distintas variaciones, como el tipo de escalado, grado (lineal o polinomial), valor de  $\eta_0$  y número de iteraciones.

Teniendo el conjunto de datos, el conjunto de entrenamiento tendrá un 80%, y el conjunto de prueba el 20% restante. Se hará uso del método de validación cruzada por pliegues, teniendo diez pliegues y revolviendo los datos de forma “aleatoria” dada a la semilla de estado aleatorio 0.

El método de regresión a utilizar será el de gradiente descendiente estocástico, puesto que, a pesar de ser inexacto, es una técnica poderosa aplicada en ciencia de datos, ya que se entrena con un único dato aleatorio de todo el conjunto de entrenamiento. Por lo que, dado que el conjunto de datos es sumamente amplio, cada entrenamiento de cada pliegue no debería representar una gran carga para el procesador, no como lo sería entrenar con todos los datos en otro método.

Debido a lo anterior, se efectuarán tres experimentos con cada tipo de regresión estocástica (siendo exactos, lineal, grado 2 y grado 3) junto con sus variantes de escalamiento. Con esto, se modificará el  $\eta_0$  y/o el número de iteraciones para observar las variaciones de promedios entre experimentos.

A continuación, se presentarán los resultados promedios de los pliegues en cada experimento del conjunto de entrenamiento. Cabe señalar que el `learning_rate` de todos fue constant.

| Tipo de regresión                              | Método de escalamiento | Valor de eta0 | Número de iteraciones | MSE promedio           | R <sup>2</sup> promedio        |
|------------------------------------------------|------------------------|---------------|-----------------------|------------------------|--------------------------------|
| Gradiente estocástico lineal (Experimento 1)   | Sin escalar            | 0.000000001   | 3000                  | 11531513967.561947     | 0.13836919270426534            |
| Gradiente estocástico lineal (Experimento 2)   | Sin escalar            | 0.000000009   | 3000                  | 11724478508.509306     | 0.12399116168447621            |
| Gradiente estocástico lineal (Experimento 3)   | Sin escalar            | 0.0000000002  | 3000                  | 11512418139.726673     | <b>0.13980375792219185</b>     |
| Estocástico polinomial grado 2 (Experimento 1) | Sin escalar            | 9.9e-19       | 20000                 | 47912677691.259796     | <b>-2.579686009984954</b>      |
| Estocástico polinomial grado 2 (Experimento 2) | Sin escalar            | 1e-19         | 20000                 | 50194826476.78699      | -2.7504952484128395            |
| Estocástico polinomial grado 2 (Experimento 3) | Sin escalar            | 5e-19         | 20000                 | 48392806954.71285      | -2.6159294325357743            |
| Estocástico polinomial grado 3 (Experimento 1) | Sin escalar            | 1e-19         | 150000                | 1.006411919050873e+36  | -7.527935173295218e+25         |
| Estocástico polinomial grado 3 (Experimento 2) | Sin escalar            | 1e-20         | 150000                | 2.0037003430214481e+34 | <b>-1.4986192288045383e+24</b> |
| Estocástico polinomial grado 3 (Experimento 3) | Sin escalar            | 9e-19         | 150000                | 5.632925895898101e+37  | -4.210303964369078e+27         |
| Gradiente estocástico lineal (Experimento 1)   | Escalado estándar      | 0.000001      | 10000                 | 4827017062.556175      | 0.6393324570992144             |

|                                                |                          |           |        |                    |                           |
|------------------------------------------------|--------------------------|-----------|--------|--------------------|---------------------------|
| Gradiente estocástico lineal (Experimento 2)   | Escalado <b>estándar</b> | 0.000009  | 10000  | 4829226879.401973  | 0.6391672020326349        |
| Gradiente estocástico lineal (Experimento 3)   | Escalado <b>estándar</b> | 0.0000002 | 50000  | 4826437823.161202  | <b>0.63937576976581</b>   |
| Estocástico polinomial grado 2 (Experimento 1) | Escalado <b>estándar</b> | 0.0000008 | 50000  | 4348168013.36204   | <b>0.6751130943735962</b> |
| Estocástico polinomial grado 2 (Experimento 2) | Escalado <b>estándar</b> | 0.0000009 | 50000  | 4352733146.32889   | 0.6747708500553498        |
| Estocástico polinomial grado 2 (Experimento 3) | Escalado <b>estándar</b> | 0.000001  | 50000  | 4352762951.21267   | 0.6747697196959338        |
| Estocástico polinomial grado 3 (Experimento 1) | Escalado <b>estándar</b> | 0.000001  | 70000  | 4097805201.3859434 | 0.6938190119515288        |
| Estocástico polinomial grado 3 (Experimento 2) | Escalado <b>estándar</b> | 0.00001   | 70000  | 4080828672.0723786 | <b>0.695087510142882</b>  |
| Estocástico polinomial grado 3 (Experimento 3) | Escalado <b>estándar</b> | 0.000005  | 70000  | 4107191719.4007864 | 0.6931163659419408        |
| Gradiente estocástico lineal (Experimento 1)   | Escalado <b>robusto</b>  | 0.00001   | 700000 | 4841332219.339614  | 0.6382626224951128        |
| Gradiente estocástico lineal (Experimento 2)   | Escalado <b>robusto</b>  | 0.00009   | 700000 | 4839462586.471041  | 0.638401984808184         |
| Gradiente estocástico lineal (Experimento 3)   | Escalado <b>robusto</b>  | 0.000002  | 700000 | 4830666918.2699    | <b>0.6390597917197196</b> |

|                                                            |                            |             |         |                    |                           |
|------------------------------------------------------------|----------------------------|-------------|---------|--------------------|---------------------------|
| Estocástico<br>polinomial<br>grado 2<br>(Experimento<br>1) | Escalado<br><b>robusto</b> | 0.000008    | 700000  | 4847470100.396875  | <b>0.6377933474465328</b> |
| Estocástico<br>polinomial<br>grado 2<br>(Experimento<br>2) | Escalado<br><b>robusto</b> | 0.000009    | 700000  | 4944255709.61912   | 0.6305923859233049        |
| Estocástico<br>polinomial<br>grado 2<br>(Experimento<br>3) | Escalado<br><b>robusto</b> | 0.00001     | 700000  | 5220449577.8491535 | 0.609892542720316         |
| Estocástico<br>polinomial<br>grado 3<br>(Experimento<br>1) | Escalado<br><b>robusto</b> | 0.000000009 | 2000000 | 12966703809.23508  | 0.03086921636216646       |
| Estocástico<br>polinomial<br>grado 3<br>(Experimento<br>2) | Escalado<br><b>robusto</b> | 0.000000003 | 3000000 | 6336352042.063276  | <b>0.5265228061572035</b> |
| Estocástico<br>polinomial<br>grado 3<br>(Experimento<br>3) | Escalado<br><b>robusto</b> | 0.000000005 | 4000000 | 7953294306.778714  | 0.40551661691099616       |

**MSE y  $r^2$  obtenido en el conjunto de prueba.**

Mejor resultado del entrenamiento: regresión estocástica de grado 3, experimento 2.

Utilizando el mismo  $\eta_0$  y las mismas iteraciones del experimento con mejor resultado en el conjunto de prueba, se obtuvo:

MSE promedio: 4268804955.80993

$R^2$  promedio: 0.6726263348347432

**Conclusiones generales de la práctica, mencionando las dificultades encontradas y algunas ideas para mejorar el resultado obtenido.**

Habiendo creado un algoritmo capaz de crear un archivo csv con los datos de prueba y los datos predichos por el algoritmo, pude sorprenderme al comparar algunas muy buenas predicciones, pero esto sería normal sabiendo que el valor de  $r^2$  promedio fue de un 67%, por lo que de cierta forma se le puede considerar como un buen resultado dado al método de regresión utilizado, además de dar buena impresión del escalado estándar.

Durante el proceso, la principal complicación que se presentó fue no poder encontrar valores de  $\eta_0$  ni de iteraciones suficientes para obtener un resultado positivo en la regresión polinomial de grado 2 y 3 sin escalado. Posiblemente, si el  $\eta_0$  hubiera sido muchísimo más pequeño, podría haber salido alentador, sin embargo, el costo de tiempo de procesamiento no lo compensaría en lo absoluto.

Y hablando de tiempo de procesamiento, el segundo problema fue el tiempo que requirieron los últimos experimentos, mayormente el grado 3 con escalado robusto, puesto que acabó tomando aproximadamente una hora obtener el resultado. En este caso, tras realizar unas pocas pruebas, los valores de  $\eta_0$  e iteraciones decidí tantearlas para evitar que me tomara más tiempo.

En general, para poder mejorar el resultado de cada experimento, primordialmente me aseguraba de que, al momento de ejecutar el programa, no me diera ninguna advertencia relacionada con la cantidad de iteraciones, la cual consistía en que estas no eran suficientes; por lo tanto, intenté que todos los experimentos de cada tipo de regresión lineal o polinomial tuvieran las mismas iteraciones, de esa forma, cada experimento podría tener un aspecto en común con los demás, siendo la única variante el valor de  $\eta_0$ .

Para aquellos experimentos en donde las iteraciones fueron distintas, simplemente fue para evitar la advertencia de iteraciones insuficientes, y debido a que tardaba demasiado en dar los resultados, preferí no realizar más pruebas para no retrasar el desarrollo del algoritmo.

Por otra parte, en el aspecto del  $\eta_0$ , que fue lo que más me dediqué a variar, busqué un intervalo que no tomara un tiempo exageradamente largo o que al menos mostrara resultados de vez en cuando (es decir, cada cierta cantidad aleatoria de minutos, pero que no fuera mucha la espera), y que me diera un resultado promedio positivo. Lo anterior me llevó a usar valores bastantes pequeños conforme avanzaba en algunos experimentos, aunque esto no en todos los casos.

Los experimentos que tengo que destacar son los de regresión polinomial de grado 2 y 3 sin escalado, puesto que, sin importar cuán pequeño fuera  $\eta_0$ , igualmente daba un resultado negativo o tardaría demasiado, por lo tanto, en esta ocasión hice la excepción.

Además, me resulta importante mencionar, en el escalado estándar, la cantidad de ceros en  $\eta_0$  fue moderadamente inferior que los anteriores experimentos, lo cual me demuestra que el escalado estándar puede sobresalir al necesitar menos tiempo de cálculo y procesamiento. Lo anterior gana fuerza al percatarme que el escalado robusto requirió una cantidad de ceros similar a los experimentos de regresión lineal sin escalado y, por si fuera poco, un considerable tiempo de espera para cálculo de datos en cada pliegue, para finalmente hallar un resultado general ciertamente descompensado y desalentador por todo que lo esto conlleva.