



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO
INGENIERÍA EN SISTEMAS COMPUTACIONALES

MACHINE LEARNING

Práctica 3: Naïve Bayes

Grupo: 6CM1

Integrantes:

- Alvarez Peñaloza, Nathan Arturo
- Hernández Pérez, Juan Manuel
- Juárez Utrilla, Edwin Josué
- Lopez Lin, Billy Yong Le

Docente:

Joel Omar Juárez Gambino

Ciudad de México, a 25 de Noviembre de 2022



1. Introducción

Los modelos de Naïve-Bayes son una clase especial de algoritmos de clasificación de Aprendizaje Automatico. Se basan en una técnica de clasificación estadística llamada “teorema de Bayes”.

Estos modelos son llamados algoritmos “Naïve”, o “Inocentes” en español. En ellos se asume que las variables predictoras son independientes entre sí. En otras palabras, que la presencia de una cierta característica en un conjunto de datos no está en absoluto relacionada con la presencia de cualquier otra característica.

A menudo proporciona una mejor precisión de clasificación en conjuntos de datos en tiempo real que cualquier otro clasificador. También requiere una pequeña cantidad de datos de entrenamiento. El clasificador Naïve-Bayes aprende de los datos de entrenamiento y luego predice la clase de la instancia de prueba con la mayor probabilidad posterior.

El clasificador Naïve-Bayes se puede implementar con diferentes variantes considerando varias distribuciones de probabilidad:

- El clasificador Naïve-Bayes multinomial es adecuado para la clasificación con características discretas. Es una de las clasificaciones de aprendizaje supervisado más populares que se utiliza para el análisis de los datos de texto categóricos. La distribución multinomial normalmente requiere recuentos de características enteras. Sin embargo, en la práctica, los recuentos fraccionarios también pueden funcionar.
- El clasificador Naïve-Bayes Bernoulli, al igual que Naïve-Bayes multinomial, es adecuado para datos discretos. La diferencia es que mientras Naïve-Bayes multinomial funciona con recuentos de ocurrencias, Naïve-Bayes Bernoulli está diseñado para características binarias/booleanas.
- Finalmente, el clasificador Naïve-Bayes Gaussiano, se emplea cuando los valores predictores son continuos y se espera que sigan una distribución gaussiana.

En esta práctica emplearemos usaremos las variantes Multinomial y Gaussiana, y descartaremos el uso de la variante de Bernoulli, puesto que nuestros datos no se limitan a ser booleanos. A partir de las pruebas, compararemos los resultados obtenidos y seleccionaremos el modelo con los mejores resultados para finalmente hacer las comprobaciones con el set de prueba.

2. Desarrollo

2.1. Fase de entrenaiento

Resultados con 3 pliegues

Dataset	Clasificación	Accuracy Promedio
iris.csv	Gaussiana	0.9476190476190477
iris.csv	Multinomial	0.7904761904761904
emails.csv	Gaussiana	0.9704424265459819
emails.csv	Multinomial	0.9482047612622093

En estas pruebas con los sets de validación podemos observar que, en el primer caso, con el data set *Iris* el modelo Gaussiano obtiene mejores resultados que el modelo Multinomial. Probablemente esto se deba a que el data set *Iris* es un data set de datos continuos, por lo que el modelo Gaussiano es el más adecuado para este tipo de datos.

En el segundo caso, con el data set *Emails* los resultados son muy similares, pero el modelo Gaussiano obtiene un resultado ligeramente superior al modelo Multinomial. Aunque el modelo Gaussiano está diseñado para datos continuos, podemos observar que puede funcionar bien con datos discretos.

Resultados con el set de entrenamiento completo (70 %)

Iris.csv

Class	Precision	Recall	F1-score	Support
Iris-setosa	1	1	1	34
Iris-versicolor	0.91	0.91	0.91	32
Iris-virginica	0.92	0.92	0.92	39




Figura 1: Matriz de confusión del set de entrenamiento de Iris.csv

Emails.csv

Class	Precision	Recall	F1-score	Support
0	1	0.96	0.98	2561
1	0.90	1	0.95	1059




Figura 2: Matriz de confusión del set de entrenamiento de Emails.csv

2.2. Fase de prueba

Resultados con el set de prueba (30 %)

Iris.csv

Class	Precision	Recall	F1-score	Support
Iris-setosa	1	1	1	16
Iris-versicolor	1	1	1	18
Iris-virginica	1	1	1	11




Figura 3: Matriz de confusión del set de prueba de Iris.csv

Emails.csv

Class	Precision	Recall	F1-score	Support
0	1	0.96	0.98	1099
1	0.90	1	0.95	454




Figura 4: Matriz de confusión del set de prueba de Emails.csv

3. Conclusion

Debido a la relativa simplicidad del algoritmo de Naive-Bayes, se obtuvieron resultados satisfactorios desde el principio sin necesidad de ajustar demasiados parámetros. Los únicos ajustes extraordinarios fueron en el dataset *Email* para descartar la columna ID debido a que no aportaba información relevante para el entrenamiento del modelo y para convertir los tipos de datos al nombrar las clases “0” o “1” (“ham” o “spam” respectivamente).

El algoritmo se comportó de manera similar tanto en la fase de entrenamiento como en la de pruebas obteniendo una precisión muy alta en ambos casos. Tal como pudimos observar, el modelo Multinomial se comporta mejor con datos discretos. Sin embargo, podemos advertir que el modelo Gaussiano puede funcionar bien tanto con datos discretos como con continuos.

La clasificación de datos tiene una gran cantidad de aplicaciones en diferentes campos de la ciencia y la tecnología. De manera similar a este caso, la clasificación de texto está ganando popularidad porque hay una enorme cantidad de información disponible en correos electrónicos, reseñas, documentos, etc. que necesita ser analizada. Conocer el contexto alrededor de un determinado tipo de texto ayuda a encontrar la percepción de un software o producto para los usuarios que lo van a utilizar. El algoritmo Naive-Bayes es una herramienta muy útil para este tipo de tareas, ya que es muy rápido y preciso, por lo que vale la pena aprender sobre él y considerarlo para futuros proyectos.