

Instituto Politécnico Nacional
Escuela Superior de Cómputo



Alumno:

Miranda Santiago Gustavo Ángel

Alvarez Peñaloza Nathan Arturo

Juarez Utrilla Edwin Josue

Lopez Lin Billy Yong Le

Profesor:

Juarez Gambino Joel Omar

Carrera:

Ingeniería en Sistemas Computacionales

Grupo:

6 CM 1

Asignatura:

Machine Learning

Practica No 4:

Simple Perceptron Classifier

Tablas de resultado

Prueba de 4 épocas

Pliegue 1		
Número de época	Pesos	accuracy promedio
4	0.19131962 -0.57792115 -0.55176897 0.89673601 2.68278202 -0.5850614 -0.58040581 1.40741558 -0.59339114 -0.58959659 -0.56048559 -0.58127066 -0.55835192	0.5531914893617021
Pliegue 2		
Número de época	Pesos	accuracy promedio
4	0.32770259 -0.60504026 -0.59602319 1.41533648 2.41064548 -0.60628117 -0.61988512 1.32143583 -0.61931715 -0.62502521 -0.59615882 -0.6172473 -0.59014217	0.46808510638297873
Pliegue 3		
Número de época	Pesos	accuracy promedio
4	0.32337574 -0.60428998 -0.59487574 1.40960096 2.42028212 -0.60553545 -0.61892787 1.31442537 -0.6185299 -0.62413502 -0.59567636 -0.6162407	0.4647887323943662

	-0.58947314	
Accuracy promedio 3 folds	0.4953551093796824	

Prueba de 3 épocas

Pliegue 1		
Número de época	Pesos	accuracy promedio
3	0.22409699 0.47313106 0.5060584 -0.67749891 -3.1683833 0.48248936 0.48812303 -0.64985173 0.46241897 0.47322487 0.46816089 0.47434487 0.4436855	0.45390070921985815
Pliegue 2		
Número de época	Pesos	accuracy promedio
3	0.32581848 -0.61363506 -0.59173651 1.52017442 2.1783407 -0.61124257 -0.63364132 1.54535909 -0.63436873 -0.64561195 -0.6005989 -0.6344051 -0.60445256	0.5319148936170213
Pliegue 3		
Número de época	Pesos	accuracy promedio
3	0.09699455 -0.57241085 -0.52961633 1.2140811 2.67916746 -0.57025408 -0.58147425	0.5140845070422535

	1.17233449 -0.59115797 -0.59696098 -0.57350841 -0.57964441 -0.56755033	
Accuracy promedio 3 folds	0.4999667032930443	

Prueba de 10 épocas

Pliego 1		
Número de época	Pesos	accuracy promedio
10	0.19132292 -0.57792204 -0.55176951 0.8967405 2.68277508 -0.5850623 -0.58040655 1.40742238 -0.59339218 -0.5895974 -0.56048645 -0.58127155 -0.55835289	0.5531914893617021
Pliego 2		
Número de época	Pesos	accuracy promedio
10	0.32744392 -0.60476112 -0.5960095 1.41200268 2.41587429 -0.60605993 -0.61950018 1.31686697 -0.61891277 -0.6244517 -0.59595425 -0.6168222 -0.58971621	0.44680851063829785
Pliego 3		
Número de época	Pesos	accuracy promedio
10	0.32770968 -0.60482043	0.4647887323943662

	-0.5960534 1.41318252 2.4149272 -0.60613156 -0.61956409 1.31698674 -0.61897112 -0.6245716 -0.59602015 -0.61686072 -0.58981307	
Accuracy promedio 3 folds	0.4647887323943662	

Proceso de entrenamiento


Número de época	Pesos	accuracy promedio
3	0.32581984 -0.61363517 -0.59173663 1.52017607 2.17833971 -0.61124268 -0.63364148 1.54535815 -0.63436884 -0.64561205 -0.60059904 -0.63440521 -0.60445267	0.5283018867924528

Proceso de testeo

	precisión	recall	f1-score	support
0.0	0.49	0.52	0.51	44
0.1	0.52	0.49	0.51	47
accuracy			0.51	91
macro avg	0.51	0.51	0.51	91
weighted avg	0.51	0.51	0.51	91

[[23 21]
[24 23]]

Matriz de confusión



Conclusiones

Esta práctica nos mostró otra aplicación que tiene el machine learning en su ámbito de clasificadores, ya que el clasificador por percepción o perceptrón es capaz de funcionar como una neurona humana debido a que con el uso de estas se pueden crear una red neuronal o unidad básica de inferencia en forma de discriminador lineal, a partir de lo cual se desarrolla un algoritmo capaz de generar un criterio para seleccionar un sub-grupo a partir de un grupo de componentes más grande que se puede utilizar para generar una red neuronal más compleja con la implementación de otros perceptrones.

Durante la elaboración de esta práctica se tuvo problemas al momento de obtener la respectiva matriz de confusión ya que antes los resultados que se reflejaban eran puros 0's por lo cual algo en el algoritmo no era correcto, para resolverlo tuvimos que cambiar los target names para que al momento de ser usados cambiarán a variables de tipo Float para que fueren compatibles con los datos que recibe la matriz de confusión.

Otro problema es que al momento de aplicar muchas épocas los valores de accuracy se reducían en vez de subir para demostrar la mejora pero cuando se aplicaron pocas épocas esta reflejaban de mejor manera los accuracy demostrando que hay una mejora durante la ejecución del algoritmo.